Отчёт по семинару и ДЗ: метагеномика 16S

Иващенко Владимир Даниилович, группа Б06-303б
Кластер calc.cod.phystech.edu, логин studfbmf01_19
QIIME 2 2024.10.1 · SLURM job 97260 · DADA2 trim 25 / trunc 200 / maxEE 3

1. Семинар: кишечная микробиота мышей

Разобран эксперимент Rosshart et al., Cell 2017. Germ-free мышам C57BL/6 переносили лабораторную микробиоту (L / LR) либо микробиоту диких мышей (W / WR). Секвенировали участок V4 16S, Illumina MiSeq 2×250.

1.1. Контроль качества

Для QC взял образец W1. Длина ридов 250 нт, GC около 53%. Средний Phred R1 = 33.1, R2 = 31.6. У forward качество держится выше Q30 примерно до 170-й позиции и дальше снижается. Reverse заметно хуже на конце. Риды начинаются с TACGT/TACGG — праймер 515F уже срезан. Поэтому в DADA2 ставил --p-trim-left-f/r 0, --p-trunc-len-f 200, --p-trunc-len-r 180.

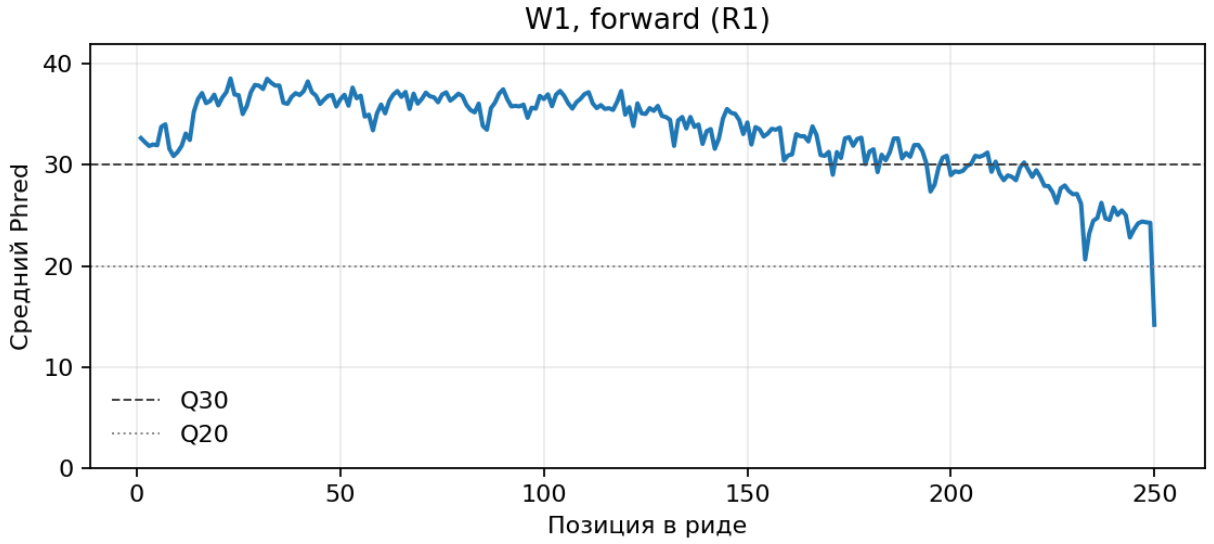


Рис. 1. Профиль качества W1 R1.

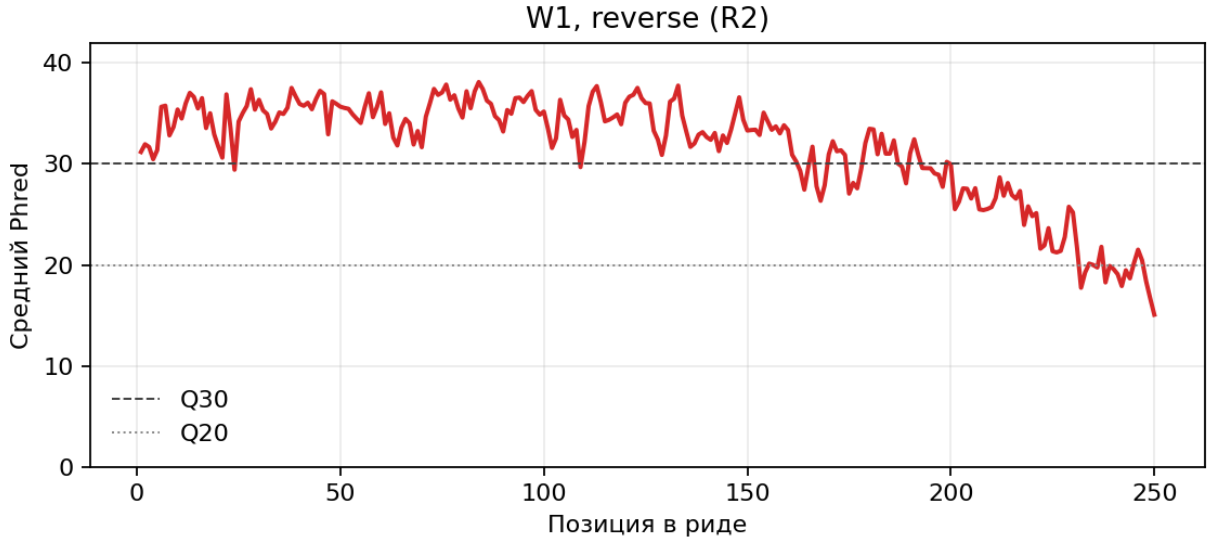


Рис. 2. Профиль качества W1 R2.

1.2. DADA2

После фильтрации, склейки пар и удаления химер остаётся около 70% входных ридов. Пример L1: 3773 → 2708 (71.8%). По группе среднее non-chimeric 71.6% (диапазон 61.5–79.1%). Для укороченных семинарских файлов это нормальный выход.

1.3. Таксономия и бета-разнообразие

Классификация GreenGenes2 2022.10, регион V4. На barplot (Level 3) лабораторные и «дикие» сообщества разделяются по набору классов. Weighted UniFrac PCoA подтверждает тот же раскол: L/LR и W/WR лежат отдельно.

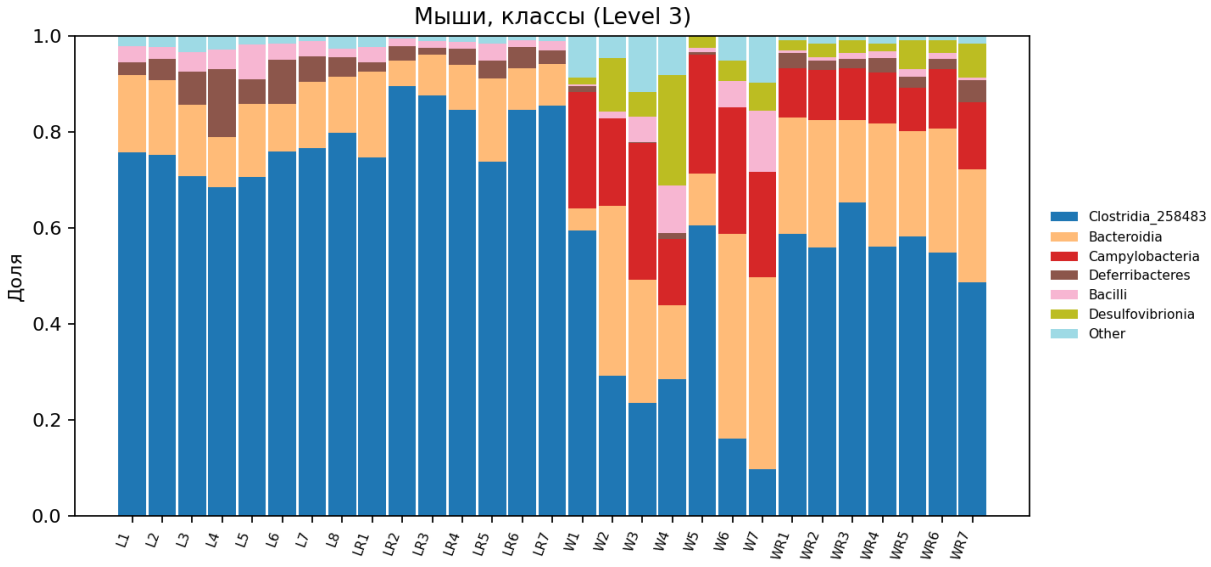


Рис. 3. Таксономический состав мышей, Level 3.

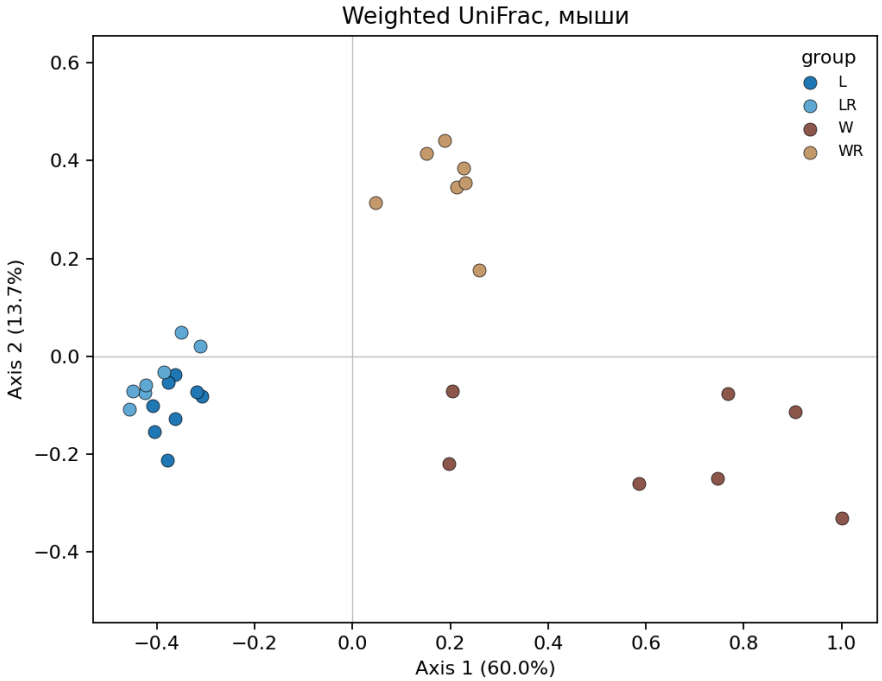


Рис. 4. PCoA Weighted UniFrac, цвет = group.

PERMANOVA по колонке group, 999 перестановок, все пары значимы:

сравнение	pseudo-F	p	q
L vs LR	5.47	0.001	0.001
L vs W	22.90	0.001	0.001

L vs WR	31.91	0.001	0.001
LR vs W	21.56	0.001	0.001
LR vs WR	28.50	0.001	0.001
W vs WR	9.38	0.002	0.002

Разница лабораторной и дикой микробиоты сильнее, чем отличие донора от реципиента внутри одного типа. Перенос (R) не стирает исходный сигнал.

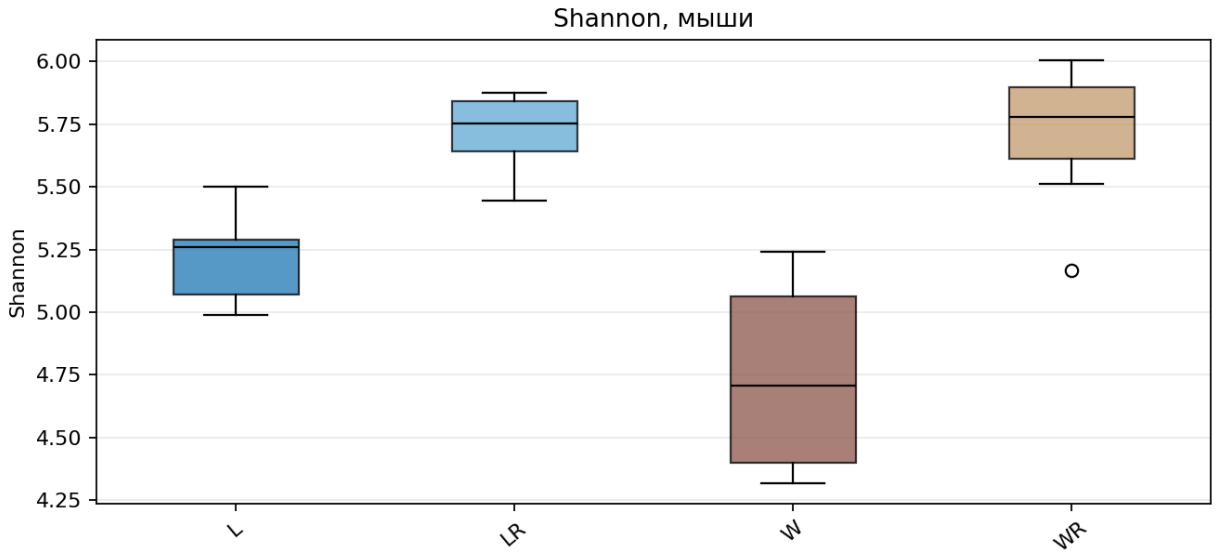


Рис. 5. Индекс Шеннона по группам мышей.

2. Домашнее задание: почва и керосин

Дерново-подзолистая почва (Albic Luvisols), дозы k0 / k5 / k25 г керосина на кг, точки d3, d90, d180, d360, по три реплики. Ампликон V4–V5, в работу взяты только R1.

Задача 1. FastQC

Образец SRR17307316 (контроль k0, день 3): 10 833 рида × 251 нт, GC 57.5%, средний Phred 35.8. Среднее качество не падает ниже Q30 ни на одной позиции, N почти нет. Старт ридов GTGCC/GTGTC — это 515F, праймер не срезан. Сырые данные хорошие; обрезка нужна из-за праймера, а не из-за «убитого» конца.

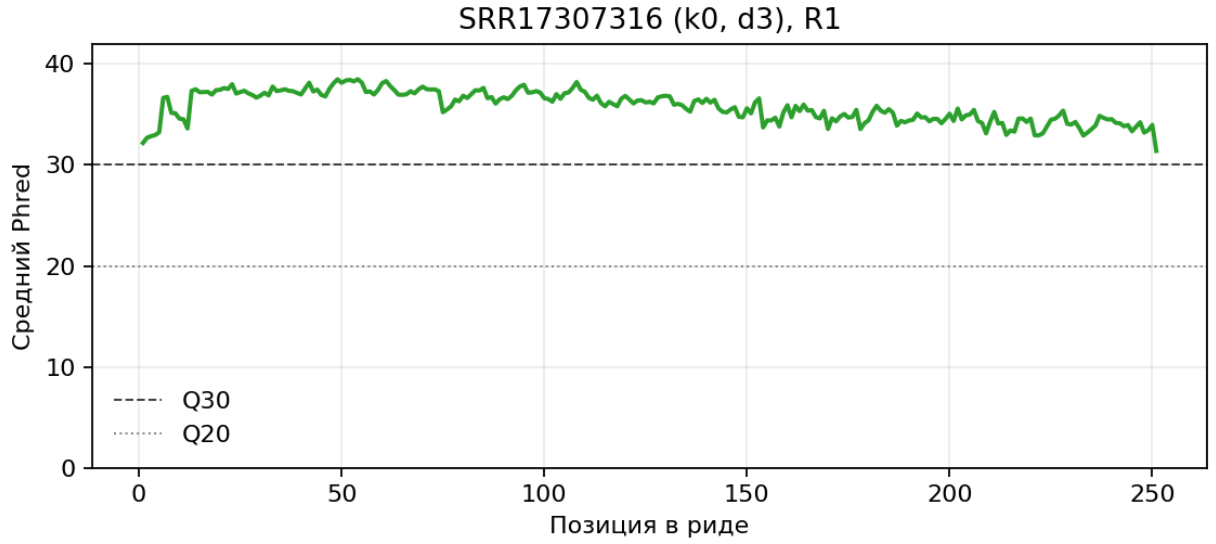


Рис. 6. FastQC-профиль SRR17307316.

Задача 2. Зачем --p-trim-left 25

515F = 19 нт (GTGCCAGCMGCCGCGGTAA). Эти основания внесены при ПЦР и не несут биологического сигнала. Первые циклы MiSeq к тому же шумнее. --p-trim-left 25 снимает праймер и ещё несколько нуклеотидов с 5′-конца. Если их оставить, ошибки в праймере породят ложные ASV.

Задача 3. Доля ридов после фильтрации

По таблице DADA2 (36 образцов) после всех стадий остаётся в среднем 94.9% ридов (мин. 89.4%, макс. 97.1%). Самый большой образец — SRR17307475: 45492 → 43518. Самый маленький — SRR17307380: 5128 → 4809. Почти ничего не теряется на filter/denoise/chimera. Глубина секвенирования различается почти на порядок, поэтому diversity считали с rarefaction по мелким образцам.

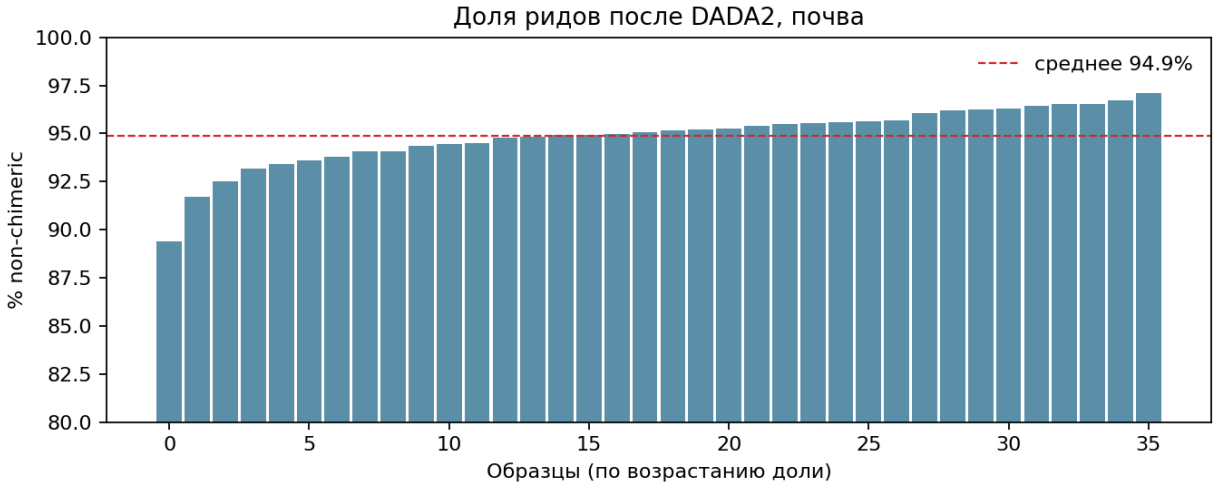


Рис. 7. Процент non-chimeric по образцам почвы.

Задача 4. Почему классификатор только на V4

Праймеры 515F–907R дают V4–V5 (~400 нт). Мы используем только R1 длиной 250 нт. После trim 25 и trunc 200 остаётся участок от начала V4. До V5 (сторона 907R) эти риды не доходят. Классификатор GreenGenes2, обученный на V4 (515F/806R), совпадает с тем, что реально лежит в ASV.

Задача 5. Состав сообществ

На d3 (t1) k0, k5 и k25 почти одинаковы: Acidobacteriae ~18–20%, Alphaproteobacteria ~16–17%, Actinomycetia ~11%, Gammaproteobacteria ~9–10%. За три дня сообщество ещё не перестроилось. Дальше контроль накапливает Acidobacteriae (до ~48%), k5 временно отдаёт место гаммапротеобактериям и частично откатывается к d360, k25 захватывается Gammaproteobacteria (32% → 61% → 88%). На уровне рода в загрязнённых образцах лидирует Paraburkholderia: при k25 к году около 84%. Это типичные деструкторы углеводородов.

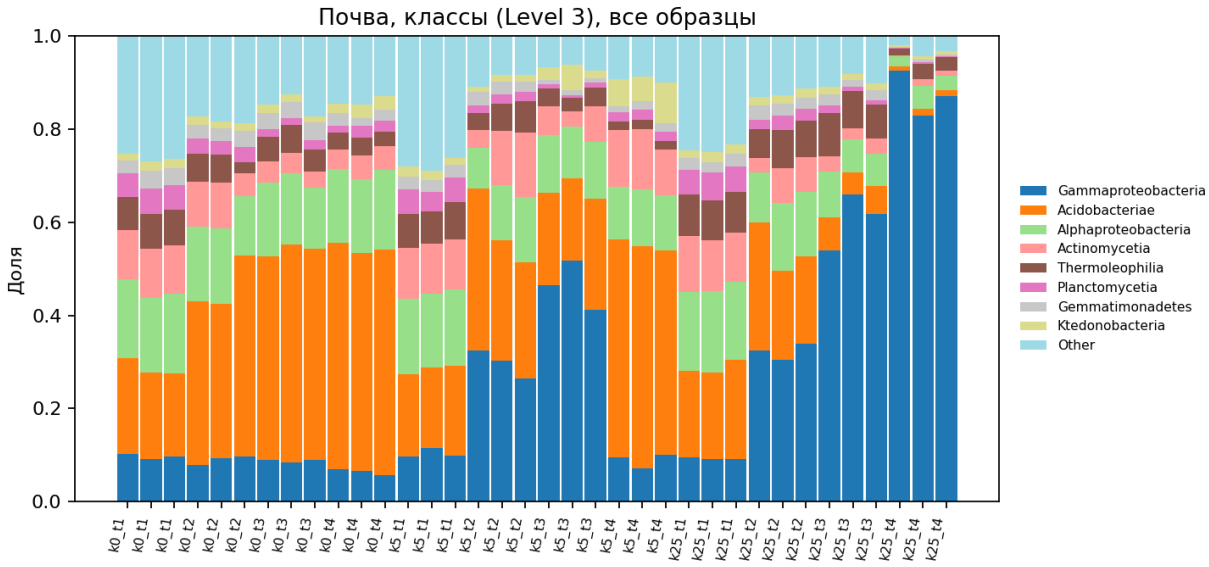


Рис. 8. Level 3, сортировка level_and_time_point.

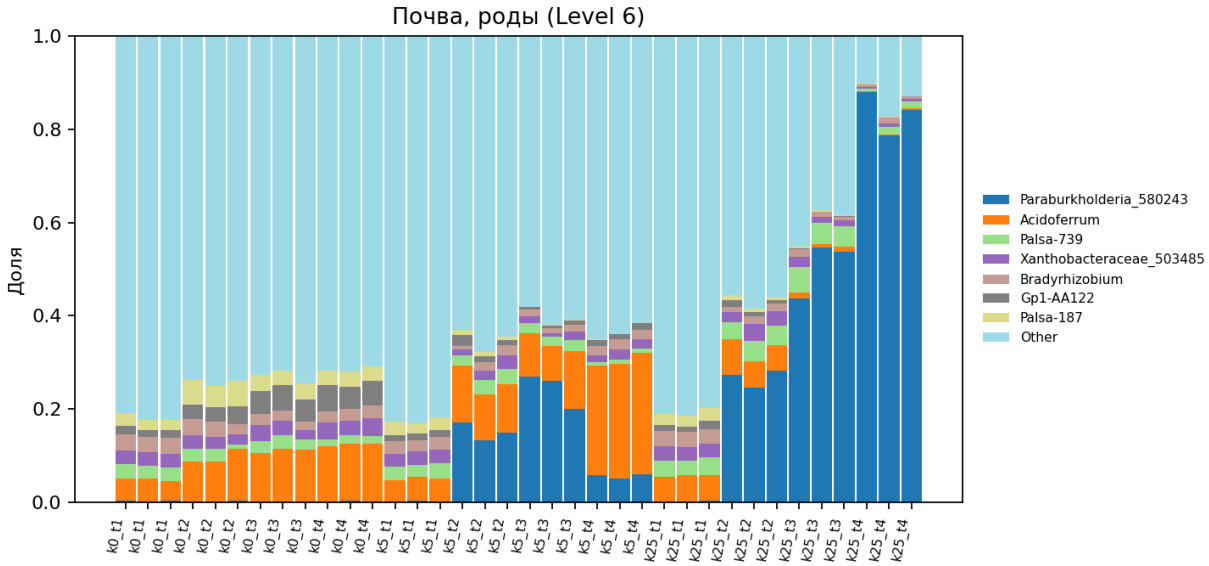


Рис. 9. Level 6: выход Paraburkholderia при k25.

Задача 6. Weighted UniFrac

На d3 все точки (k0/k5/k25) сидят вместе. Затем вдоль Axis 1 уезжают загрязнённые образцы, особенно k25 на d180 и d360. k5 на d360 сдвигается обратно к контролю — признак частичного восстановления. k25 не возвращается: сдвиг за год необратим.

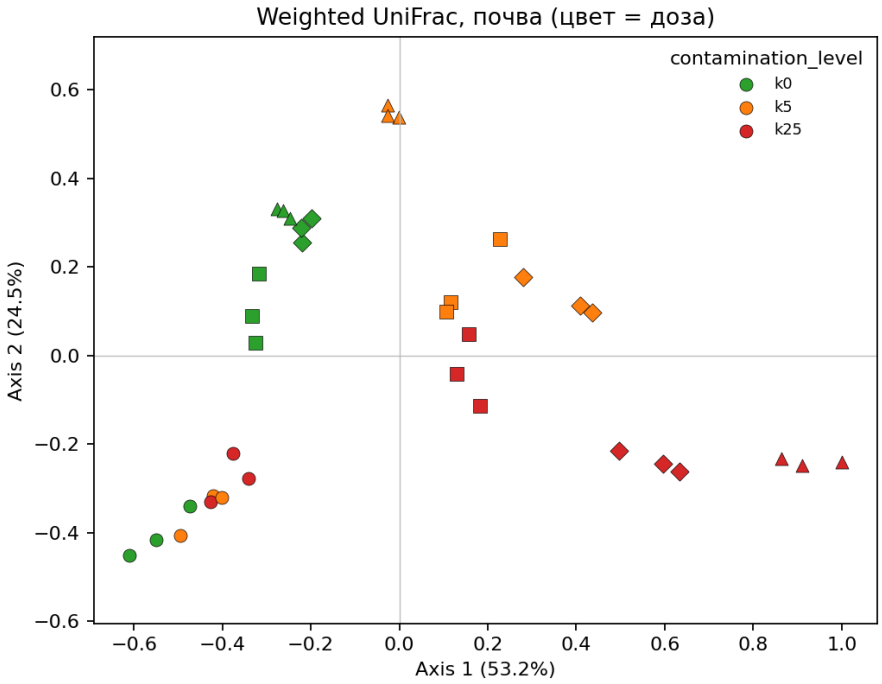


Рис. 10. PCoA Weighted UniFrac почвы.

Задача 7. Индекс Шеннона

На d3 разнообразие одинаковое (~8.4–8.6). У k0 оно почти не падает. У k5 снижается к d180 (6.37) и слегка отскакивает к d360 (6.63). У k25 к году коллапс: среднее Shannon 2.79. Kruskal–Wallis: k0 vs k25 p = 0.028, k0 vs k5 p = 0.038, k5 vs k25 p = 0.15.

группа	d3	d90	d180	d360
k0	8.44	8.37	8.24	7.97
k5	8.57	7.39	6.37	6.63
k25	8.48	7.31	5.66	2.79

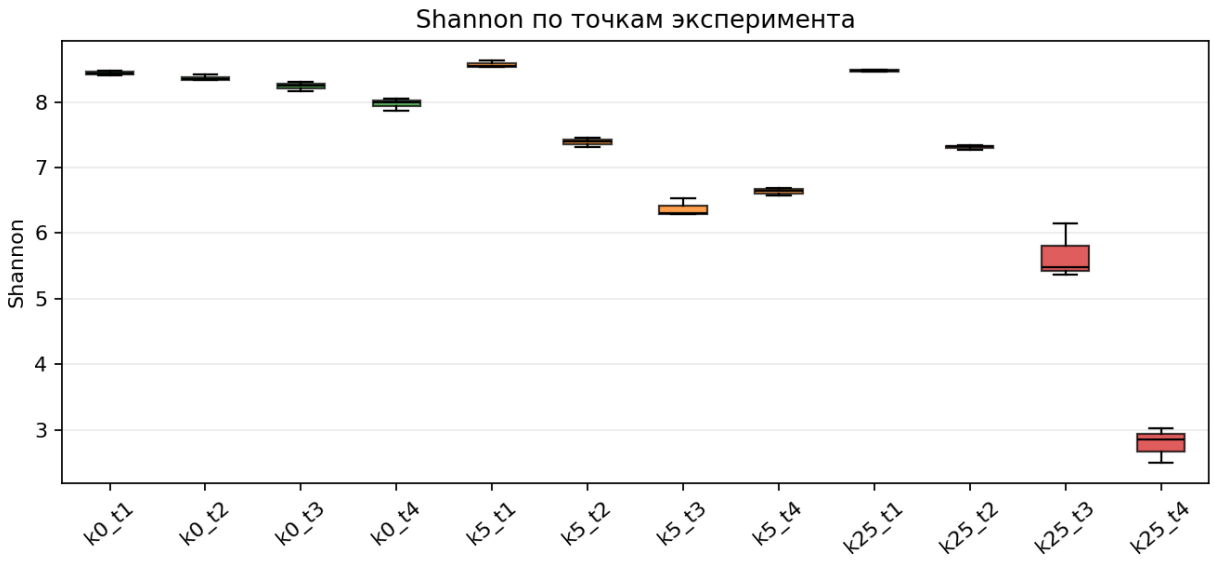


Рис. 11. Боксплоты Shannon по точкам.

3. Вывод

Семинар: лабораторная и дикая микробиота мышей различаются и по составу, и по Weighted UniFrac (все pairwise PERMANOVA значимы). ДЗ: слабое загрязнение (k5) меняет сообщество обратимо, сильное (k25) — нет. Доминирует Paraburkholderia, альфа-разнообразие при k25 падает почти втрое.

Расчёт: QIIME 2 2024.10.1, Singularity, calc.cod.phystech.edu, SLURM job 97260. Графики построены по таблицам из соответствующих .qzv.